

Akıllı Doküman Anlama Sistemlerinde Dinamik Yönlendirme Mekanizmaları: Proje Planı ve Literatür Değerlendirmesi

Yönetici Özeti

Bu rapor, doküman anlama (document understanding) süreçlerinde sorgu niteliğine bağlı olarak metin tabanlı, görüntü tabanlı veya hibrit işleme yollarını otomatik seçen dinamik bir yönlendirme mekanizmasının geliştirilmesine yönelik üç haftalık araştırma ve planlama sürecini kapsamaktadır. Modern doküman işleme sistemleri, OCR hataları, karmaşık düzen yapıları ve yüksek işlem maliyetleri gibi zorluklarla karşı karşıyadır. Mevcut literatür, tek tip (fixed) yöntemlerin her senaryoda optimal performans sergileyemediğini göstermektedir [3], [4]. Yapılan incelemeler, dinamik yönlendirme stratejilerinin maliyeti %30-77 oranında azaltırken doğruluğu koruduğunu veya artırdığını kanıtlamaktadır [15], [18]. Bu çalışma, "dinamik yöntem seçiminin sabit yöntemlere göre kalite-maliyet-gecikme dengesini iyileştirip iyileştirmediği" hipotezini test etmeyi amaçlamaktadır.

Hafta 1: Proje Başlangıcı ve Kapsam Tanımı

Projenin ilk aşamasında, sistemin sınırları ve temel kullanım senaryoları netleştirilmiştir. Sistemin temel amacı, gelen bir kullanıcı sorgusunun (query) ve ilgili dokümanın özelliklerini analiz ederek en verimli işleme yolunu (pipeline) belirlemektir.

Sistem Sınırları ve Kullanım Senaryoları

Sistem; taranmış dokümanlar (scanned PDF), dijital doğan dokümanlar (digital-born PDF) ve fotoğraflar üzerinden bilgi çıkarımı yapacaktır. Temel kullanım senaryoları şunlardır:

- Metin Odaklı Sorgular:** Doküman içindeki düz metinlerden yanıt aranan durumlar (örneğin; sözleşme maddeleri).
- Görsel/Düzen Odaklı Sorgular:** Tablo yapısı, imzalar veya logo gibi görsel öğelerin analizini gerektiren durumlar [3].
- Hibrit Sorgular:** Hem metinsel hem de görsel kanıtların birleştirilmesini gerektiren karmaşık akıl yürütme görevleri [1].

Araştırma Sorusu ve Hipotez

Araştırma Sorusu: Sorguya dayalı dinamik yöntem seçimi, doküman anlama görevlerinde doğruluktan ödün vermeden maliyet ve gecikme süresini nasıl optimize eder?

Hipotez: Dinamik yöntem seçimi (routing), sabit tek-yöntem yaklaşımlarına (her zaman metin veya her zaman görüntü) kıyasla kalite-maliyet-gecikme dengesinde anlamlı bir iyileşme sağlar. Literatürde, yönlendirme mekanizmalarının işlem süresinde %169 ila %1151 arasında bir iyileşme sağlayabildiği görülmüştür [6].

Proje Yapılandırması

Proje için gerekli altyapı şu şekilde kurgulanmıştır:

- **Kod Deposu:** Modüler bir Python tabanlı mimari.
- **Veri Yapısı:** Eğitim ve test setleri için DocVQA [28], TableDART [3] ve MMR-Bench [4] gibi standart veri setlerinin entegrasyonu.
- **Yayın Planı:** Çalışmanın "Akıllı Doküman Anlama İçin Dinamik Çok Modlu Yönlendirme" başlığı altında, *IEEE Transactions on Pattern Analysis and Machine Intelligence* veya *Artificial Intelligence* dergilerine aday olması hedeflenmektedir.

Hafta 2: Literatür Taraması I - Doküman Anlama ve Çok Modlu Modeller

İkinci haftada, doküman anlama alanındaki temel yaklaşımlar incelenmiş ve metodolojik bir karşılaştırma yapılmıştır.

OCR Tabanlı Yaklaşımlar ve Görsel Modeller

Doküman anlama çalışmaları geleneksel olarak OCR motorlarına (Tesseract, PaddleOCR vb.) dayanmaktadır [25]. Ancak, OCR hataları özellikle düşük kaliteli taramalarda performansı olumsuz etkilemektedir [24].

- **OCR-Free (Görsel) Modeller:** Donut ve DiT gibi yaklaşımlar, metin çıkarmadan doğrudan görsel pikseller üzerinden çalışır [9], [23]. Bu modeller, yerleşim (layout) bilgilerini koruma konusunda daha başarılıdır ancak yüksek çözünürlüklü görsellerde hesaplama yükü artmaktadır [19].
- **Hibrit Modeller:** LayoutLM serisi ve DocVLM gibi modeller, hem OCR çıktılarını hem de görsel özellikleri birleştirerek daha zengin bir temsil oluşturur [22], [27].

Karşılaştırmalı Analiz

Metin tabanlı modeller (LLM'ler) yapılandırılmamış veride yüksek başarı sağlarken, görsel modeller (VLM'ler) form ve tablo anlama görevlerinde öne çıkmaktadır [3], [26]. Literatür matrisine göre; UniDoc-Bench çalışmaları, görsel bağlamın metinsel kanıtları ne zaman tamamladığının kritik bir performans metriği olduğunu göstermektedir [13].

Yöntem	Güçlü Yönler	Zayıf Yönler
Metin Tabanlı (LLM)	Hızlı, düşük maliyetli (dijital PDF'ler için)	Görsel ipuçlarını ve düzeni kaçıır
Görsel Tabanlı (VLM)	Yerleşim ve grafik farkındalığı yüksek	Hesaplama maliyeti ve token sayısı fazladır [19]
Hibrit (Early/Late Fusion)	En yüksek doğruluk potansiyeli [22]	Karmaşık mimari, yüksek gecikme [21]

Hafta 3: Literatür Taraması II ve Araştırma Boşluğunun Netleştirilmesi

Üçüncü haftada, projenin özgün yönü olan "dinamik yönlendirme" ve "uzman karışımı (MoE)" yaklaşımlarına odaklanılmıştır.

Dinamik Yönlendirme ve Uzman Karışımı (MoE)

Modern sistemler, her sorgu için en pahalı modeli kullanmak yerine, sorgu karmaşıklığına göre model seçen router mekanizmaları kullanmaktadır.

- Maliyet Duyarlı Yönlendirme:** CSCR gibi yöntemler, FAISS tabanlı k-NN araması kullanarak mikrosaniye düzeyinde gecikme ile maliyet-başarı dengesini %25 iyileştirmektedir [5].
- Uzman Karışımı (MoE):** AnyExperts gibi çalışmalar, metin yoğun görevler (OCR/NLP) ile görsel görevler arasında uzman aktivasyonunu adaptif olarak dengeleyerek gerçek uzman kullanımını %10-40 oranında azaltmaktadır [17].
- Sorgu Karmaşıklığı Analizi:** Adaptive-RAG, sorunun tek adımlı mı yoksa çok adımlı mı olduğunu belirleyerek işlem süresini 8.81 saniyeden 3.60 saniyeye düşürebilmektedir [20].

Araştırma Boşluğu ve Özgün Katkı

Literatürdeki çalışmaların çoğu ya sadece metin tabanlı yönlendirmeye [5], [16] ya da sadece görsel retrieval optimizasyonuna [2] odaklanmaktadır. Bu projenin özgünlüğü; **metin, görüntü ve hibrit yolların her üçünü de kapsayan, hem sorgu içeriğini hem de doküman karmaşıklığını aynı anda değerlendiren bütüncül bir router mimarisi** sunmasıdır. Ayrıca,

literatürdeki mevcut benchmark'ların çoğu maliyet (cost) ve gecikme (latency) metriklerini doğrulukla eş zamanlı olarak optimize etmede yetersiz kalmaktadır [7], [12].

Başarı Kriterleri ve Karşılaştırma Stratejisi

Deneyler sırasında şu dört temel yaklaşım karşılaştırılacaktır:

1. **Sabit Metin (Always-Text):** Sadece OCR ve LLM kullanımı.
2. **Sabit Görüntü (Always-Image):** Sadece VLM (OCR-free) kullanımı.
3. **Sabit Hibrit (Always-Hybrid):** Her sorgu için en kapsamlı modelin kullanımı.
4. **Dinamik Seçim (Proposed Routing):** Sorguya göre yol seçimi.

Hedeflenen Başarı Kriterleri:

- Sabit hibrit yöntemine kıyasla maliyette en az %30 azalma [18].
- Sabit görüntü yöntemine kıyasla gecikmede %70 iyileşme [11].
- En güçlü modelin doğruluğunu (accuracy) %95 oranında koruma [15].

Sonuç

Bu üç haftalık süreç sonunda, projenin kavramsal çerçevesi literatürdeki en güncel çalışmalarla desteklenerek oluşturulmuştur. Dinamik yönlendirme mekanizmalarının, özellikle kurumsal doküman işleme süreçlerinde kaynak verimliliği sağlamak adına kritik bir öneme sahip olduğu doğrulanmıştır. Projenin sonraki aşamalarında, TableDART [3] ve PolyRouter [18] mimarilerinden esinlenen bir "gating network" tasarımı gerçekleştirilecektir.

Kaynakça

- [1] Towards Complex Document Understanding By Discrete Reasoning, 2022.
- [2] AVIR: Adaptive Visual In-Document Retrieval for Efficient Multi-Page Document Question Answering, 2026.
- [3] TableDART: Dynamic Adaptive Multi-Modal Routing for Table Understanding, 2025.
- [4] MMR-Bench: A Comprehensive Benchmark for Multimodal LLM Routing, 2026.
- [5] Cost-Aware Contrastive Routing for LLMs, 2025.
- [6] Efficient Neuro-Symbolic Retrieval-Augmented Generation through Adaptive Query Routing, 2025.
- [7] GraphDocNet: Efficient Multimodal Document Intelligence with Graph-Aware Transformers.
- [8] Vision-driven Adaptive Decoding for Document Understanding: A Dual-Path Visual-Language and OCR Framework with Prompt-aware Task Routing.
- [9] Interpret, prune and distill Donut : towards lightweight VLMs for VQA on document, 2025.
- [10] AdaNav: Query-Adaptive Multi-granularity Navigation for Long Document Understanding.

- [11] Docslm: A small vision-language model for long multimodal document understanding, 2025.
- [12] EcoDoc: A cost-efficient multimodal document processing system for enterprises using LLMs, 2025.
- [13] Unidoc-bench: A unified benchmark for document-centric multimodal rag, 2025.
- [14] Towards Resource-Efficient Multimodal Intelligence: Learned Routing among Specialized Expert Models, 2025.
- [15] Pre-Inference Routing for Cost-Efficient Document Field Extraction, 2026.
- [16] L-RAG: Balancing Context and Retrieval with Entropy-Based Lazy Loading, 2026.
- [17] AnyExperts: On-Demand Expert Allocation for Multimodal Language Models with Mixture of Expert, 2025.
- [18] PolyRouter: A Multi-LLM Querying System, 2024.
- [19] Hierarchical Visual Feature Aggregation for OCR-Free Document Understanding, 2024.
- [20] Adaptive-RAG: Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity, 2024.
- [22] DocVLM: Make Your VLM an Efficient Reader, 2024.
- [25] A Hybrid Architecture for Multi-Stage Claim Document Understanding: Combining Vision-Language Models and Machine Learning for Real-Time Processing, 2026.
- [26] Zero-Shot Document Understanding using Pseudo Table of Contents-Guided Retrieval-Augmented Generation, 2025.
- [27] Unifying Vision, Text, and Layout for Universal Document Processing, 2022.
- [28] Docvqa: A dataset for vqa on document images, 2020.

Kaynakça Ayrıntıları

[1]

authors: Zhu, Fengbin; Lei, Wenqiang; Feng, Fuli; Wang, Chao; Zhang, Haozhou; Chua, Tat-Seng

title: Towards Complex Document Understanding By Discrete Reasoning

issued: 2022-07-25

doi: 10.1145/3503161.3548422

url: <https://scispace.com/papers/towards-complex-document-understanding-by-discrete-reasoning-4pzhq8c1>

[2]

authors: Li, Zongmin; Li, Yachuan; Kang, Lei; Karatzas, Dimosthenis; Ma, Wenkang

title: AVIR: Adaptive Visual In-Document Retrieval for Efficient Multi-Page Document Question Answering

source: arXiv

issued: 2026-01-17

url: <https://arxiv.org/abs/2601.11976v1>

[3]

authors: Xiaobo, Xing; Wei, Yuan; Tong, Chen; Hung, Nguyen Quoc Viet; Xiangliang, Zhang; Hongzhi, Yin,

title: TableDART: Dynamic Adaptive Multi-Modal Routing for Table Understanding

issued: 2025-09-19

doi: 10.48550/arxiv.2509.14671

url: <https://scispace.com/papers/tabledart-dynamic-adaptive-multi-modal-routing-for-table-mac3zd7801hi>

[4]

authors: Ma, Haoxuan; Lai, Guannan; Ye, Han-Jia

title: MMR-Bench: A Comprehensive Benchmark for Multimodal LLM Routing

issued: 2026-01-25

doi: 10.48550/arxiv.2601.17814

url: <https://scispace.com/papers/mmr-bench-a-comprehensive-benchmark-for-multimodal-llm-9cs48barrsny>

[5]

authors: Shirkavand, Reza; Gao, Shangqian; Yu, Peng; Huang, Heng

title: Cost-Aware Contrastive Routing for LLMs

issued: 2025-08-17

doi: 10.48550/arxiv.2508.12491

url: <https://scispace.com/papers/cost-aware-contrastive-routing-for-llms-fuhoh0mnk1a0>

[6]

authors: Bin, Hakim, Safayat; Muhammad, Adil; Alvaro, Velasquez,; Houbing, Song,

title: Efficient Neuro-Symbolic Retrieval-Augmented Generation through Adaptive Query Routing

issued: 2025-07-10

doi: 10.13016/m2nr6x-zk7b

url: <https://scispace.com/papers/efficient-neuro-symbolic-retrieval-augmented-generation-0edaav3349z0>

[7]

authors: Dutta, S; Maurya, AK; Kumar, A

title: GraphDocNet: Efficient Multimodal Document Intelligence with Graph-Aware Transformers

source: Google Scholar

url: <https://ieeexplore.ieee.org/abstract/document/11493138/>

[8]

authors: Shen, A; Chen, T; Sun, Y; Jiang, F; Feng, Y

title: Vision-driven Adaptive Decoding for Document Understanding: A Dual-Path Visual-Language and OCR Framework with Prompt-aware Task Routing

source: Google Scholar

url: <https://ieeexplore.ieee.org/abstract/document/11451708/>

[9]

authors: Mansour, Adnan Ben; Karine, Ayoub; Naccache, David

title: Interpret, prune and distill Donut : towards lightweight VLMs for VQA on document

source: arXiv

issued: 2025-09-30

url: <https://arxiv.org/abs/2509.26235v1>

[10]

authors: Xu, Y; López, E; Llabrés, A; Hormazábal, M

title: AdaNav: Query-Adaptive Multi-granularity Navigation for Long Document Understanding

source: Google Scholar

url: https://link.springer.com/chapter/10.1007/978-3-032-36023-6_4

[11]

authors: Hannan, T.; Mallios, Dimitrios; Pathak, Parth; Sardari, Faegheh; Seidl, Thomas; Bertasius, Gedas; Fayyaz, Mohsen; Sengupta, Sunando

title: DocSLM: A Small Vision-Language Model for Long Multimodal Document Understanding

journal: arXiv.org

volume: abs/2511.11313

issued: 2025-11-14

doi: 10.48550/arxiv.2511.11313

url: <https://scispace.com/papers/docslm-a-small-vision-language-model-for-long-multimodal-ouu0798afee2>

[12]

authors: Rajendran, Ravi K.; Debnath, Biplob; Sankaradass, Murugan; Chakradhar, Srimat

title: EcoDoc: A cost-efficient multimodal document processing system for enterprises using LLMs

source: Google Scholar

issued: 2025-01-01

doi: 10.18653/v1/2025.acl-industry.109

url: <https://aclanthology.org/2025.acl-industry.109/>

[13]

authors: Xiangyu, Peng,; Can, Qin,; Zeyuan, Chen; Ran, Xu; Caiming, Xiong,; Chien-Sheng, Wu,

title: UNIDOC-BENCH: A Unified Benchmark for Document-Centric Multimodal RAG

issued: 2025-10-07

doi: 10.48550/arxiv.2510.03663

url: <https://scispace.com/papers/unidoc-bench-a-unified-benchmark-for-document-centric-5bqetvkj559p>

[14]

authors: Saini, Mayank; Bishwas, Arit Kumar

title: Towards Resource-Efficient Multimodal Intelligence: Learned Routing among Specialized Expert Models

journal: arXiv.org

volume: abs/2511.06441

issued: 2025-11-09

doi: 10.48550/arxiv.2511.06441

url: <https://scispace.com/papers/towards-resource-efficient-multimodal-intelligence-learned-l362xwe4ve68>

[15]

authors: Rajendran, Sreerekha

title: Pre-Inference Routing for Cost-Efficient Document Field Extraction

source: arXiv

issued: 2026-08-06

url: <https://arxiv.org/abs/2608.06607v1>

[16]

authors: Voloshyn, S.

title: L-RAG: Balancing Context and Retrieval with Entropy-Based Lazy Loading

issued: 2026-01-10

doi: 10.48550/arxiv.2601.06551

url: <https://scispace.com/papers/l-rag-balancing-context-and-retrieval-with-entropy-based-gr7xioiakgk4>

[17]

authors: Gao, Yuting; Lan, Wang; Zhao, Hengyuan; Huang, Linjiang; Liu, Si; Guo, Qingpei

title: AnyExperts: On-Demand Expert Allocation for Multimodal Language Models with Mixture of Expert

journal: arXiv.org

volume: abs/2511.18314

issued: 2025-11-23

doi: 10.48550/arxiv.2511.18314

url: <https://scispace.com/papers/anyexperts-on-demand-expert-allocation-for-multimodal-tqnam82bxbtr>

[18]

authors: Stripelis, Dimitris; Hu, Zijian; Zhang, Jipeng; Xu, Zhaozhuo; Shah, Alay Dilipbhai; Han, Jin; Yao, Yuhang; Avestimehr, Salman; He, Chaoyang

title: PolyRouter: A Multi-LLM Querying System

issued: 2024-08-22

doi: 10.48550/arxiv.2408.12320

url: <https://scispace.com/papers/polyrouter-a-multi-llm-querying-system-3frk86ggyx9l>

[19]

authors: Park, Jaeyoo; Choi, Jin- Young; Park, Jeonghyung; Han, Bohyung

title: Hierarchical Visual Feature Aggregation for OCR-Free Document Understanding

issued: 2024-11-07

doi: 10.48550/arxiv.2411.05254

url: <https://scispace.com/papers/hierarchical-visual-feature-aggregation-for-ocr-free-6ba6zyv4521e>

[20]

authors: Jeong, Soyeong; Baek, Jinheon; Cho, Sukmin; Hwang, Sung Ju; Park, Jong Chun

title: Adaptive-RAG: Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity

journal: arXiv.org

volume: abs/2403.14403

issued: 2024-03-21

doi: 10.48550/arxiv.2403.14403

url: <https://scispace.com/papers/adaptive-rag-learning-to-adapt-retrieval-augmented-large-3cxs2ro37p>

[21]

authors: Qian, Kun; Li, Wenjie; Sun, Tianyu; Wang, Wenhong; Luo, Wenhan

title: DocRefine: An Intelligent Framework for Scientific Document Understanding and Content Optimization based on Multimodal Large Model Agents

journal: arXiv.org

volume: abs/2508.07021

issued: 2025-08-09

doi: 10.48550/arxiv.2508.07021

url: <https://scispace.com/papers/docrefine-an-intelligent-framework-for-scientific-document-w2gkyuf5922y>

[22]

authors: Nacson, Mor Shpigel; Aberdam, Aviad; Ganz, Roy; Avraham, Elad Ben; Golts, Alona; Kittenplon, Yair; Mazor, Shai; Litman, Ron

title: DocVLM: Make Your VLM an Efficient Reader

issued: 2024-12-11

doi: 10.48550/arxiv.2412.08746

url: <https://scispace.com/papers/docvlm-make-your-vlm-an-efficient-reader-6snyzq7t6bmv>

[23]

authors: SR, Nikitha; Menta, Tarun Ram; Sarkar, Mausoom

title: DoPTA: Improving Document Layout Analysis using Patch-Text Alignment

issued: 2024-12-17

doi: 10.48550/arxiv.2412.12902

url: <https://scispace.com/papers/dopta-improving-document-layout-analysis-using-patch-text-270bielskepx>

[24]

title: DUBLIN -- Document Understanding By Language-Image Network

issued: 2023-05-23

doi: 10.48550/arxiv.2305.14218

url: <https://scispace.com/papers/dublin-document-understanding-by-language-image-network-bvhr2ltq>

[25]

authors: Cheng, Lili; Lu, Jingjun; Chan, Yi Xuan; Nguyễn, Quốc Khải; Bi, John; Ho, Sean

title: A Hybrid Architecture for Multi-Stage Claim Document Understanding: Combining Vision-Language Models and Machine Learning for Real-Time Processing

issued: 2026-01-05

doi: 10.48550/arxiv.2601.01897

url: <https://scispace.com/papers/a-hybrid-architecture-for-multi-stage-claim-document-iem9i5xy0klq>

[26]

authors: Seong, Jeong Hyeon; Haedong, Jeong,; Taehoon, Kim

title: Zero-Shot Document Understanding using Pseudo Table of Contents-Guided Retrieval-Augmented Generation

issued: 2025-08-01

doi: 10.48550/arxiv.2507.23217

url: <https://scispace.com/papers/zero-shot-document-understanding-using-pseudo-table-of-ubmfefe7v2cl>

[27]

authors: Tang, Zineng; Yang, Ziyi; Wang, Guoxin; Fang, Yuwei; Liu, Yang; Zhu, Chenguang; Zeng, Michael; Zhang, Chao; Bansal, Mohit

title: Unifying Vision, Text, and Layout for Universal Document Processing

journal: arXiv.org

volume: abs/2212.02623

issued: 2022-12-05

doi: 10.48550/arXiv.2212.02623

url: <https://scispace.com/papers/unifying-vision-text-and-layout-for-universal-document-3un5tn32>

[28]

authors: Mathew, Minesh; Karatzas, Dimosthenis; Jawahar, C. V.

title: DocVQA: A Dataset for VQA on Document Images

journal: arXiv: Computer Vision and Pattern Recognition

issued: 2020-07-01

url: <https://scispace.com/papers/docvqa-a-dataset-for-vqa-on-document-images-2fro0qwtum>